

Operaciones de Aprendizaje Automático III

Actualizando un Large Language Model

MSc. Fernando Silva



Agenda

- LoRA y QLoRA
- Direct Preference Optimization (DPO)
- Caso: Actualizando un LLM


LoRA y QLoRA

LoRA

- LoRA reduce el número de parámetros entrenables y los requisitos de memoria, manteniendo un buen rendimiento.
- LoRA añade pares de matrices de descomposición de bajo rango (llamadas matrices de actualización) a cada capa del LLM.
- Solo se entrenan las matrices de actualización, que tienen significativamente menos parámetros que los pesos originales del modelo.


LoRA

LoRA adapters - personalized models




LoRA

Standard




LoRa




QLoRA


Standard




LoRa



QLoRA



QLoRA



1 `get_peft_model(model, LoraConfig(**LORA))` → crea un adapter en cada módulo de `target_modules`

2 `from_pretrained(..., quantization_config=BitsAndBytesConfig(load_in_4bit=True))` → modelo base en 4-bit



Ejercicio


QLoRA y adaptadores

[LINK](#)

Direct Preference Optimization (DPO)

Direct Policy Optimization

Es un método que logra el mismo objetivo que RLHF (alinear el modelo con preferencias) sin necesitar RL ni un modelo de recompensa separado.



El papel de la sigmoide: cuando un ejemplo ya está bien aprendido, el gradiente se vuelve muy pequeño y el modelo deja de insistir con él, así se concentra en los ejemplos donde todavía se equivoca

el loss es bajo cuando el modelo mejoró su preferencia por la respuesta buena respecto al original

Prompt: cual es la capital de España?


Chosen: Madrid

Rejected: Barcelona

Prompt + chosen: cual es la capital de España? Madrid

Prompt + rejected: cual es la capital de España? Barcelona

Direct Preference Optimization





Ejercicio DPO

[LINK](#)

Caso: Actualizando un LLM


Caso




Actualizando un LLM

Un asistente que se reentrena solo cada vez que cambia lo que sus usuarios prefieren, y el sistema de control que decide si la versión nueva entra a producción o se descarta. Con DPO sobre QLoRA

Flujo



Flujo



Actualizando un LLM

LLMOps

¿qué decidimos y por qué?
una fila por ronda con la decisión, su causa y el hash del lote que la produjo

¿de donde salió este par?
guarda el prompt entero junto a cada par, y separa lo que el sistema puede leer de lo que no

Falta para cerrar el ciclo: versionado de datos, verificación automática (CI) y el registry como mecanismo de promoción.

¿entra a producción?
cuatro condiciones conjuntivas que deciden sin humano, y una reversión si sale mal

¿cambió algo?

deriva medida sobre lo observable, no sobre una etiqueta que no existe, sin alarma no se entrena

LLM
OPs

Promoción

LLM
OPs

Registro

LLM
OPs

Trazabilidad

LLM
OPs

Monitoreo

LLM
OPs

Evaluación

LLM
OPs

Contrato de
datos

¿es mejor, o tuve suerte?
el intervalo, no el punto más una métrica de guardarraíl que nadie intenta mejorar

¿esto sirve para entrenar?
descartamos el par inservible antes de armar el lote, no después de evaluar el resultado

DPO +
QLoRA

Entrenamiento